

Cahier des charges

MIASHS M1 IC
2025-2026

Cahier des charges	1
Présentation générale du projet	3
Projet	3
Contexte	3
Situation du projet	3
Projets déjà effectués en BUT	3
Projet TER actuel	4
Travail à réaliser	4
Matériel	4
Données & confidentialité	5
Personnels	5
Technologies	5
Cas d'utilisation client	6

Présentation générale du projet

Projet

L'objectif du projet est de concevoir une interface logicielle permettant à un utilisateur de décrire textuellement sa situation juridique, afin d'obtenir un pourcentage de chances de réussite et d'échec, des exemples de cas juridiques similaires ainsi que le nombre d'affaires similaires ayant abouti favorablement. Ce projet s'appuie sur des techniques de Traitement Automatique du Langage Naturel (TALN) et de classification supervisée.

Ce projet s'inscrit dans le cadre d'un **Travail d'Étude et de Recherche (TER)**, en collaboration avec le **Laboratoire GATE**, le LIG, l'IMAG ainsi que l'IDEX. Il mobilise des compétences en apprentissage automatique, en analyse de textes juridiques et en ingénierie des données.

Contexte

Situation du projet

12/12/2025	Obtention du sujet TER
15/12/2025	Accès gitlab
09/01/2026	Obtention de la convention d'accueil
12/01/2026	Rédaction du cahier des charges
01/02/2026	Début du travail

Projets déjà effectués en BUT


Classification des commentaires amazon de la catégorie grocery store en 2 catégories, positif et négatif. La classification s'est faite grâce au contenu textuel du commentaire et sur le nombre d'étoiles attribuées à cette note. De plus, nous avons déjà réalisé plusieurs classification au cours de notre premier semestre et du BUT. Ces expériences constituent une base solide pour le projet actuel.

Projet TER actuel

Un ingénieur de Laboratoire Gate nommé Louis MARITAUD, présent auparavant sur le projet a développé un modèle permettant d'effectuer une classification.

Différentes technologies de traitement automatique du langage naturel (TALN) ont été utilisées et appliquées à différents traitements de données. Certaines de ces technologies reposent sur un pipeline CPU, d'autres sur un pipeline GPU. Dans un premier temps, ils ont tenté d'appliquer le TALN soit aux objets et à leurs étiquettes de qualification, soit aux objets seuls, soit aux qualifications seules. Les résultats n'ont pas été concluants. ils ont ensuite essayé d'entraîner le modèle sur chaque élément « considérant », afin d'étiqueter les différentes parties comme étant ou non une plainte. Enfin, il a été décidé de scinder l'étiquette « objet » en deux parties : la première correspondant à ce qui précède le premier tiret bas, la seconde à ce qui le suit.

Répartition des décisions rattachées à un résultat d'élection



Travail à réaliser

Permettre d'identifier automatiquement la catégorie du droit à laquelle appartient une décision de justice, à partir de son contenu textuel.

Pour cela, notre objectif est de vérifier le modèle déjà créé afin d'améliorer sa précision et son accuracy sur une plus large quantité de données. La précision est un indicateur simple mais essentiel en apprentissage automatique. Elle mesure la proportion de prédictions correctes réalisées par un modèle par rapport au nombre total de prédictions. Idéal serait donc d'obtenir un recall se rapprochant de 1. C'est-à-dire une classification parfaite des cas. Afin d'obtenir de meilleurs scores il sera probable de refaire un nouveau modèle basé sur de nouvelles entrées. De plus, il nous faudra baisser l'intervalle de confiance du modèle précédent et augmenter le nombre de classes pour la classification.

Matériel

Nous aurons à notre disposition :

- un gitlab, gestionnaire de version du code source du projet
- Une base de données (SQL, fichiers Excel ou données issues d'un site web)
- Une salle de travail dédiée au sein de l'IMAG
- <https://jade.univ-grenoble-alpes.fr/>

Données & confidentialité

Les données que nous allons utiliser sont publiques et proviennent de sites comme celui du conseil constitutionnel, donc la seule partie confidentielle de notre travail est les codes déjà produits que nous allons améliorer.

Personnels

- 2 stagiaires développeurs machine learning en Master MIAHS IC
- maître de stage développeur
- professeur de droit référent pour l'expertise métier
- professeur de base de données
- 2 stagiaires développeurs BD en Master MIAHS IC

Technologies

- Modèle en python
- xml.etree.elementTree pour l'utilisation de xml
- glob pour la recherche de fichier dans le projet
- pathlib pour la creation/suppression/... de fichier dans le systeme
- json pour l'utilisation de json et l'extraction des données et la conversion

Cas d'utilisation client

